

线性动态 系统

(Linear Dynamical
Systems)

- ① 背景
- ② 推断
- ③ 学习

背景 (Background)


HMM: 潜在变量是离散的

Linear Dynamical Systems: 潜在变量连续且满足线性与高斯

Particle Filters: 连续、非线性、非高斯

初时将 LDS 看作是连续潜在变量模型 (例如 P-PCA 和因子分析) 的推广

线性动态系统 (LDS):



$$p(z_1) = \mathcal{N}(z_1 | \mu_0, P_0)$$

$$p(z_n | z_{n-1}) = \mathcal{N}(z_n | A z_{n-1}, Q)$$

$$p(x_n | z_n) = \mathcal{N}(x_n | C z_n, R)$$

这里省略了可加性常数, 如果加上, 结果为

$$\mathcal{N}(z_n | A z_{n-1} + B, Q)$$

$$\mathcal{N}(x_n | C z_n + D, R)$$

$$z_1 = \mu_0 + \mu, \quad \mu \sim \mathcal{N}(\mu | 0, P_0)$$

$$z_n = A z_{n-1} + w, \quad w \sim \mathcal{N}(w | 0, Q)$$

$$x_n = C z_n + v, \quad v \sim \mathcal{N}(v | 0, R)$$

$$z_n = A z_{n-1} + B + w_n$$

$$x_n = C z_n + D + v_n$$

由于 LDS 是一个线性高斯模型, 因此在所有变量上的联合概率分布以及边缘概率分布和条件概率分布都是高斯分布。

推断 (Inference)

在LDS中的推断一般就是filter和smooth两个方面,

分别称之为 Kalman filter 方程和 Kalman smoother 方程.

我们可以利用之前推导得到的结果来解决这两个问题.

Kalman Filter → 重要的应用是跟踪.

记 $\hat{\alpha}(z_n) = p(z_n | x_1, \dots, x_n) = N(z_n | \mu_n, V_n)$

则递推式为: $C_n \hat{\alpha}(z_n) = p(x_n | z_n) \int \hat{\alpha}(z_{n-1}) p(z_n | z_{n-1}) dz_{n-1}$

$$C_n N(z_n | \mu_n, V_n) = N(x_n | C z_n, R) \int N(z_{n-1} | \mu_{n-1}, V_{n-1}) N(z_n | A z_{n-1}, Q) dz_{n-1}$$

公式: 给定边缘高斯分布和条件高斯分布:

$$p(x) = N(x | \mu, \Lambda^{-1}) \quad ①$$

$$p(y|x) = N(y | Ax + b, L^{-1}) \quad ②$$

则 y 的边缘高斯分布和 x 的条件高斯分布为

$$p(y) = N(y | A\mu + b, L^{-1} + \Lambda \Lambda^{-1} A^T) \quad ③$$

$$p(x|y) = N(x | \Sigma [A^T L (y - b) + \Lambda \mu], \Sigma), \Sigma = (\Lambda + A^T L A)^{-1} \quad ④$$

对于积分子, 我们可以看成给定边缘与条件概率, 求边缘概率, 应用上述公式:

$$\int N(z_{n-1} | \mu_{n-1}, V_{n-1}) N(z_n | A z_{n-1}, Q) dz_{n-1} = N(z_n | A \mu_{n-1}, P_{n-1}), P_{n-1} = Q + A V_{n-1} A^T$$

$$\text{则 } C_n N(z_n | \mu_n, V_n) = N(x_n | C z_n, R) N(z_n | A \mu_{n-1}, P_{n-1})$$

再次应用公式，得：

将 x_n 看作 y ， z_n 看作 x ，如下：

$$\begin{array}{cccc} p(x_n | x_1, \dots, x_{n-1}) & p(z_n | x_1, \dots, x_n) & = & p(x_n | z_n) p(z_n | x_1, \dots, x_{n-1}) \\ \downarrow & \downarrow & & \downarrow \\ p(y) & p(x|y) & & p(y|x) p(x) \end{array}$$

$$\mu_n = V_n (C^T R^{-1} x_n + P_{n-1}^{-1} A \mu_{n-1})$$

$$V_n = (P_{n-1}^{-1} + C^T R^{-1} C)^{-1}$$

$$C_n = N(x_n | C A \mu_{n-1}, C P_{n-1} C^T + R)$$

公式：

$$(P^{-1} + B^T R^{-1} B)^{-1} B^T R^{-1} = P B^T (B P B^T + R)^{-1} \quad (5)$$

$$(A + B D^{-1} C)^{-1} = A^{-1} - A^{-1} B (D + C A^{-1} B)^{-1} C A^{-1} \quad (6)$$

对 V_n 应用公式 (5)，得： $V_n = P_{n-1} - P_{n-1} C^T (R + C P_{n-1} C^T)^{-1} C P_{n-1}$

令 $K_n = P_{n-1} C^T (R + C P_{n-1} C^T)^{-1} \rightarrow$ Kalman 增益矩阵 (Kalman gain matrix)

得 $V_n = (I - K_n C) P_{n-1}$

对 K_n 应用公式 (5)，得： $K_n = (C^T R^{-1} C + P_{n-1}^{-1})^{-1} C^T R^{-1} = V_n C^T R^{-1}$

则 $V_n = K_n R (C^T)^{-1}$ ，代入 μ_n 。

得 $\mu_n = K_n R (C^T)^{-1} C^T R^{-1} x_n + (I - K_n C) P_{n-1} P_{n-1}^{-1} A \mu_{n-1}$

$$= A \mu_{n-1} + K_n (x_n - C A \mu_{n-1})$$

最终

$$\begin{cases} \mu_n = A \mu_{n-1} + K_n (x_n - C A \mu_{n-1}), & K_n = P_{n-1} C^T (R + C P_{n-1} C^T)^{-1} \\ V_n = (I - K_n C) P_{n-1} \\ C_n = N(x_n | C A \mu_{n-1}, C P_{n-1} C^T + R) \end{cases}$$

初始条件: $C_1 \hat{\alpha}(z_1) = p(z_1)p(x_1|z_1)$

其中: $p(z_1) = N(z_1 | \mu_0, P_0)$

$$p(x_1|z_1) = N(x_1 | C z_1, R)$$

再次应用公式①. ②. ③. ④. ⑤. ⑥. 得:

$$\mu_1 = \mu_0 + K_1(x_1 - C\mu_0)$$

$$V_1 = (I - K_1 C)P_0$$

$$C_1 = N(x_1 | C\mu_0, CP_0C^T + R)$$

$$K_1 = P_0 C^T (C P_0 C^T + R)^{-1}$$

初始条件.

因此, 给定上一时刻的 μ_{n-1} , V_{n-1} 和当前时刻的观测值 x_n , 就可以计算当前时刻 z_n 的均值 μ_n , 方差 V_n 以及归一化系数 C_n

LDS 的似然函数可以由 $p(X) = \prod_{n=1}^N C_n$ 求得.

Kalman Filter 的直观感受: 先用一个转移概率矩阵 A 对上一时刻的 μ_{n-1} 进行投影, 得到最初的 μ_n 的预测 $A\mu_{n-1}$, 这个预测也会给出 x_n 的预测 $CA\mu_{n-1}$. 当获得当前时刻的 x_n 后, 将 $x_n - CA\mu_{n-1}$ 作为一个修正项, 乘上一个修正系数 (K_n), 修正对 μ_n 的预测。总的来说, 我们是对后续进行预测, 然后用后续的观测值来修正预测

Kalman Filter 的工作流程: ($t=n$ 代表接收到 x_n , 工作流程为先 update, 再 predict)

$$\begin{aligned}
 t=1: & \begin{cases} p(z_1|x_1) & \hat{\alpha}(z_1) & \text{update} \\ p(z_2|x_1) & A\mu_1 & \\ p(x_2|x_1) & C_2 & \end{cases} \text{predict} \\
 \downarrow \\
 t=2: & \begin{cases} p(z_2|x_1, x_2) & \hat{\alpha}(z_2) & \text{update} \\ p(z_3|x_1, x_2) & A\mu_2 & \\ p(x_3|x_1, x_2) & C_3 & \end{cases} \text{predict} \\
 \downarrow \\
 \vdots \\
 \downarrow \\
 t=n: & \begin{cases} p(z_n|x_1, \dots, x_n) & \hat{\alpha}(z_n) & \text{update} \\ p(z_{n+1}|x_1, \dots, x_n) & A\mu_n & \\ p(x_{n+1}|x_1, \dots, x_n) & C_{n+1} & \end{cases} \text{predict} \\
 \downarrow \\
 \vdots
 \end{aligned}$$

先用 update 修正上一次的后验估计
再用 predict 对下一时刻进行预测

Kalman Smoother

解决的问题: 给定 x_1, \dots, x_n , 寻找 z_n 的边缘概率, 即 $p(z_n|x_1, \dots, x_n)$

类比 HMM 模型, $p(z_n|x_1, \dots, x_n) = \gamma(z_n) = \hat{\alpha}(z_n) \hat{\beta}(z_n) = N(z_n|\hat{\mu}_n, \hat{V}_n)$

借用 $\hat{\beta}(z_n)$ 的更新公式: $C_{n+1}\hat{\beta}(z_n) = \int \hat{\beta}(z_{n+1}) p(x_{n+1}|z_{n+1}) p(z_{n+1}|z_n) dz_{n+1}$

两侧乘上 $\hat{\alpha}(z_n)$ 后, 经过计算, 得:

具体过程不写了, 可以参考b站视频.

$$\hat{\mu}_n = \mu_n + J_n (\hat{\mu}_{n+1} + A \mu_n)$$

$$\hat{V}_n = V_n + J_n (\hat{V}_{n+1} - P_n) J_n^T$$

$$J_n = V_n A^T (P_n)^{-1}$$

从而, 可由 $\gamma(z_{n+1})$ 向前递归得到 $\gamma(z_n)$

注意: 该递归方程要求先完成前向过程, 得到 μ_n 和 V_n .

https://www.bilibili.com/video/BV1eb4y167wF/?spm_id_from=333.999.0.0&vd_source=e3780c93bbfab1295672c1a3f1be54d5

此外, 为了下一节的学习, 我们还需要求 $\xi(z_{n+1}, z_n)$

$$\begin{aligned} \xi(z_{n+1}, z_n) &= (C_n)^{-1} \hat{\alpha}(z_{n+1}) p(x_n | z_n) p(z_n | z_{n+1}) \boxed{\hat{\beta}(z_n)} \rightarrow \frac{\gamma(z_n)}{\hat{\alpha}(z_n)} \\ &= \frac{N(z_{n+1} | \mu_{n+1}, V_{n+1}) N(x_n | C z_n, R) N(z_n | A z_{n+1}, Q) N(z_n | \hat{\mu}_n, \hat{V}_n)}{N(x_n | C A \mu_{n+1}, C P_{n+1} C^T + R) N(z_n | \mu_n, V_n)} \end{aligned}$$

整理后, 得 $\xi(z_{n+1}, z_n)$ 的值为 $(\hat{\mu}_{n+1}, \hat{\mu}_n)^T$, 协方差为

$$\text{Cov}[z_{n+1}, z_n] = J_{n+1} \hat{V}_n$$

学习 (Learning)

使用EM算法来求解 LDS参数的极大似然估计问题. 即LDS的学习.

根据EM算法, 我们要在 $p(Z|X, \theta^{(t)})$ 这个分布上求期望,
通过前面的计算, 我们可以得到.

$$E[Z_n] = \hat{\mu}_n$$

$$E[Z_n Z_{n-1}^T] = \hat{V}_n J_{n-1}^T + \hat{\mu}_n \hat{\mu}_{n-1}^T$$

$$E[Z_n Z_n^T] = \hat{V}_n + \hat{\mu}_n \hat{\mu}_n^T$$

对数似然函数:

$$\log p(X, Z | \theta) = \log p(z_1 | \mu_0, p_0) + \sum_{n=2}^N \log p(z_n | z_{n-1}, A, Q) \\ + \sum_{n=1}^N p(x_n | z_n, C, R)$$

EM的Q函数为:

$$Q(\theta, \theta^{(t)}) = E_{z \sim p(z|x, \theta^{(t)})} [\log p(X, Z | \theta)]$$

当我们只考虑 μ_0 和 p_0 时, 代入 $p(z_1 | \mu_0, p_0) = N(z_1 | \mu_0, p_0)$

$$Q(\theta, \theta^{(t)}) = -\frac{1}{2} \log |p_0| - E \left[\frac{1}{2} (z_1 - \mu_0)^T p_0^{-1} (z_1 - \mu_0) \right] + C,$$

所有不依赖 μ_0 和 p_0 的项全部放入 C 中.

则关于 μ_0 和 p_0 最大化 $Q(\theta, \theta^{(t)})$, 就可以得到:

$$\mu_0^{(t+1)} = E[z_1]$$

$$V_0^{(t+1)} = E[z_1 z_1^T] - E[z_1] E[z_1^T]$$

当我们只考虑 A 和 Q 时, 代入 $p(z_n | z_{n-1}, A, Q) = \mathcal{N}(z_n | Az_{n-1}, Q)$

$$Q(\theta, \theta^{(t)}) = -\frac{N-1}{2} \log |Q| - E \left[\frac{1}{2} \sum_{n=2}^N (z_n - Az_{n-1})^T Q^{-1} (z_n - Az_{n-1}) \right] + C_2$$

所有不依赖 A 和 Q 的项全部放入 C_2 中。

解得:

$$A^{(t+1)} = \left(\sum_{n=2}^N E[z_n z_n^T] \right) \left(\sum_{n=2}^N E[z_{n-1} z_{n-1}^T] \right)^{-1}$$

$$Q^{(t+1)} = \frac{1}{N-1} \sum_{n=2}^N \left\{ E[z_n z_n^T] - A^{(t+1)} E[z_{n-1} z_{n-1}^T] \right. \\ \left. - E[z_n z_n^T] (A^{(t+1)})^T + A^{(t+1)} E[z_{n-1} z_{n-1}^T] (A^{(t+1)})^T \right\}$$

当我们只考虑 C 和 R 时, 代入 $p(x_n | z_n, C, R) = \mathcal{N}(x_n | Cz_n, R)$

$$Q(\theta, \theta^{(t)}) = -\frac{N}{2} \log |R| - E \left[\frac{1}{2} \sum_{n=1}^N (x_n - Cz_n)^T R^{-1} (x_n - Cz_n) \right] + C_3$$

所有不依赖 C 和 R 的项全部放入 C_3 中

解得:

$$C^{(t+1)} = \left(\sum_{n=1}^N x_n E[z_n^T] \right) \left(\sum_{n=1}^N E[z_n z_n^T] \right)^{-1}$$

$$R^{(t+1)} = \frac{1}{N} \sum_{n=1}^N \left\{ x_n x_n^T - C^{(t+1)} E[z_n] x_n^T \right. \\ \left. - x_n E[z_n^T] (C^{(t+1)})^T + C^{(t+1)} E[z_n z_n^T] (C^{(t+1)})^T \right\}$$

上面的结果直接出自PRML, 我没有推导过, 可以参考PRML中第二章的内容
或者b站视频: https://www.bilibili.com/video/BV1a64y1z7y5/?spm_id_from=333.999.0.0&vd_source=e3780c93bbfab1295672c1a3f1be54d5

有兴趣可以看一下PRML中的LDS的推广